

INSTITUTO TECNOLÓGICO Y DE ESTUDIOS SUPERIORES DE MONTERREY

CAMPUS ESTADO DE MÉXICO

**Operaciones de aprendizaje automático**

**Gpo. 10**

# Código de experimentación base con MLFlow


**Nombre:**

Leonardo Cossio Dinorin

**Matrícula:**

A01753898


**Fecha de entrega:**

11/10/2026

**Comparación general:**

Se realizaron cinco corridas del modelo XGBoost, modificando los hiperparámetros *n_estimators*, *max_depth* y *learning_rate*, manteniendo fija la semilla aleatoria en 42 para garantizar condiciones de comparación consistentes. Los resultados se registraron mediante MLflow Tracking y se evaluaron utilizando cuatro métricas: accuracy, precision, recall y F1-score. La siguiente tabla presenta los resultados obtenidos para cada configuración, tomando como referencia el modelo base desarrollado en la actividad anterior.

| Corrida | Árboles | Profundidad | Learning rate | Accuracy | Precision | Recall | F1 Score |
|---|---|---|---|---|---|---|---|
| **Baseline** | 200 | 6 | 0.05 | 0.6265 | 0.5230 | 0.4883 | 0.5051 |
| **Menos árboles** | 100 | 6 | 0.05 | 0.6479 | 0.5527 | 0.5117 | 0.5314 |
| **Más árboles** | 300 | 6 | 0.05 | 0.6159 | 0.5085 | 0.4648 | 0.4857 |
| **Menor profundidad** | 200 | 3 | 0.05 | 0.6067 | 0.4962 | 0.5156 | 0.5057 |
| **Mayor aprendizaje** | 200 | 6 | 0.10 | 0.6402 | 0.5450 | 0.4727 | 0.5063 |

Los resultados muestran que la configuración con 100 árboles obtuvo el mejor desempeño general, alcanzando un accuracy de 64.79% y un F1-score de 0.5314, superando al modelo base en las cuatro métricas. La cantidad de árboles presentó la mayor influencia observada sobre el F1-score, ya que aumentarla a 300 redujo el rendimiento a 0.4857. Esto sugiere que una mayor complejidad no necesariamente mejora las predicciones. Sin embargo, el desempeño general sigue siendo moderado y las cinco configuraciones evaluadas representan una exploración limitada, por lo que sería conveniente realizar pruebas adicionales y validación cruzada para obtener conclusiones más sólidas.

## Capturas de pantalla de MLFlow:

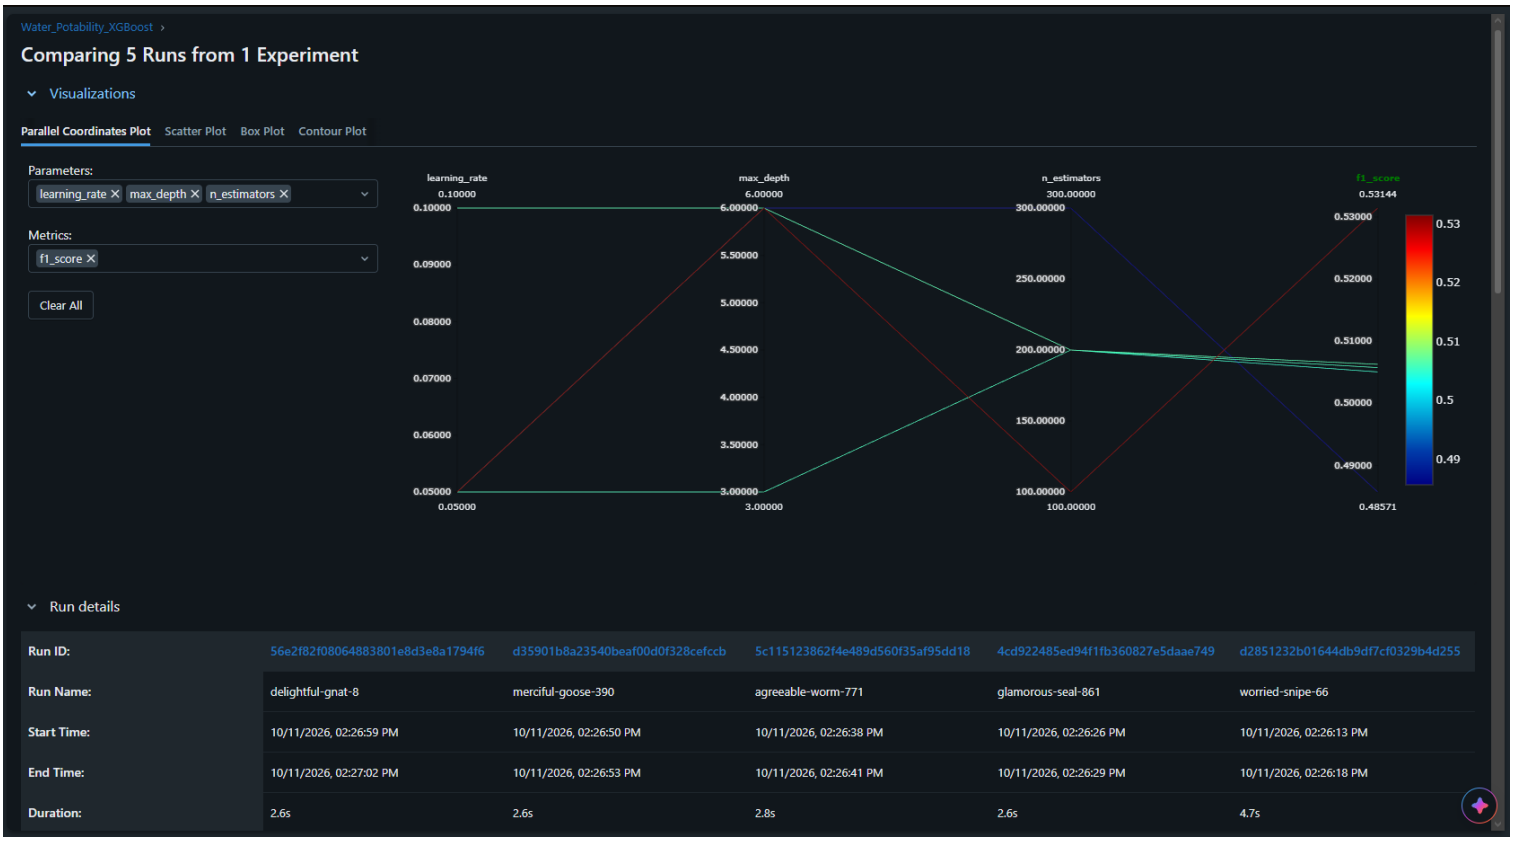



***Figura 1**. Comparación de cinco corridas del modelo XGBoost mediante la visualización de coordenadas paralelas de MLflow, mostrando la relación entre los hiperparámetros evaluados y el F1-score obtenido.*

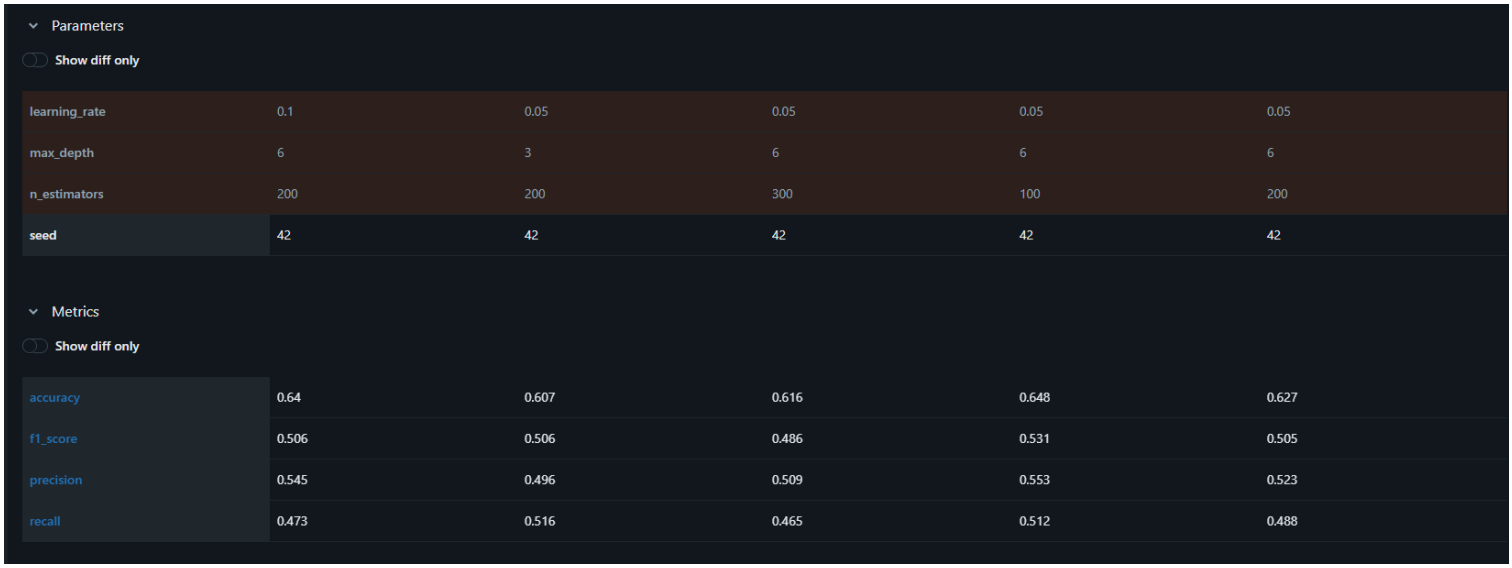



***Figura 2.** Comparación de parámetros y métricas de evaluación de cinco corridas del modelo XGBoost registradas en MLflow Tracking, manteniendo fija la semilla aleatoria para facilitar la comparación de resultados.*

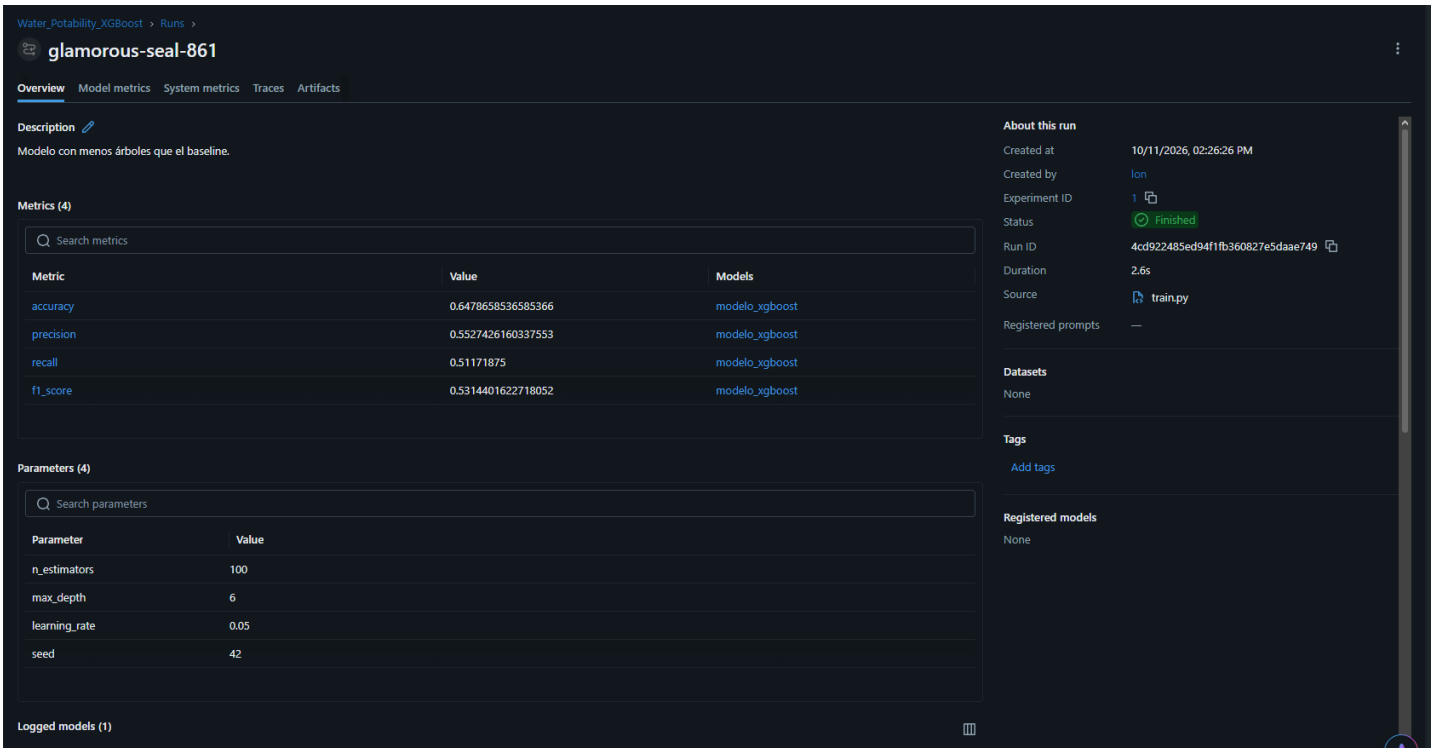



***Figura 3.*** *Detalle de la corrida con mejor desempeño en MLflow Tracking, mostrando los hiperparámetros utilizados, las métricas de evaluación y el modelo XGBoost registrado.*




***Figura 4.*** *Matriz de confusión de la configuración con mejor F1-score, registrada como artefacto en MLflow. Se observan 294 verdaderos negativos, 131 verdaderos positivos, 106 falsos positivos y 125 falsos negativos.*

**Conclusión:**

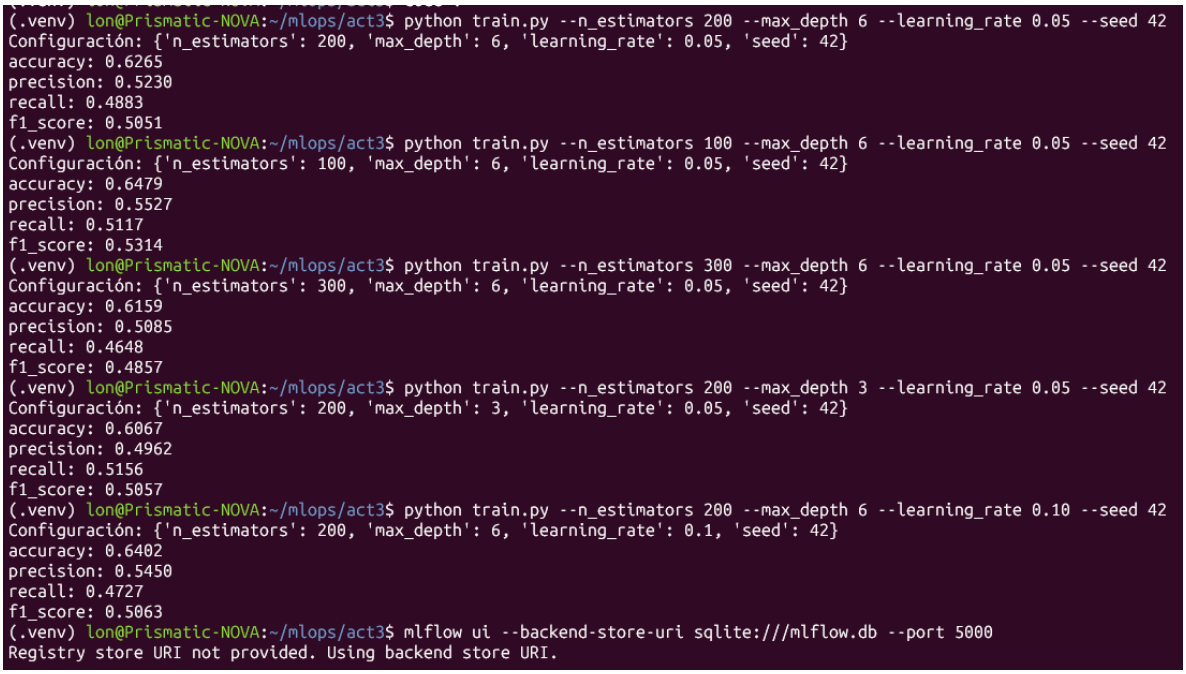
Esta actividad permitió comprender la importancia de organizar y documentar los experimentos de Machine Learning para facilitar su ejecución, comparación y reproducibilidad. Al migrar el modelo XGBoost de un notebook a un script parametrizado e integrar MLflow Tracking, fue posible registrar distintas configuraciones, evaluar su desempeño y conservar tanto las métricas como los artefactos generados.

Los resultados demostraron que aumentar la complejidad del modelo no necesariamente mejora su rendimiento, ya que la configuración con menos árboles obtuvo el mejor F1-score. Aunque el desempeño predictivo todavía presenta limitaciones, el ejercicio permitió identificar oportunidades de mejora mediante la comparación sistemática de hiperparámetros.

Finalmente, esta actividad ayudó a comprender cómo las prácticas de MLOps van más allá del entrenamiento de modelos, al incorporar herramientas que permiten mantener un registro organizado de los experimentos y facilitar su reproducción y análisis posterior.

**Comando de ejecución:**

*python train.py --n_estimators 100 --max_depth 6 --learning_rate 0.05 --seed 42*




**Enlace a repositorio de Github:**

https://github.com/LeoCossio/MLOps_A01753898/tree/9a106b05db05f943dd9bf9901229f9faae296010/ExperimentacionConMLFlow